

证据驱动的行业研究系统：方法论与验证结果

版本：v1.0 (2026-08-02) 对应代码状态：main @ ba07d3a (CI 全绿, 分支保护已启用) 素材来源：
CONTEXT.md、PRODUCT.md、docs/evaluation/ 证据包

摘要

Fund Engine 是一套证据驱动的行业研究系统，目标不是“生成一份看起来完整的研究报告”，而是让研究员能够持续回答四个问题：当前行业命题得到什么支持、受到什么反驳、仍缺什么证据、判断如何随时间变化。系统以不可变证据账本为核心，AI 判断与人类复核以分离记录共存、机器结论永不被覆盖；所有判断可沿“评估 → 快照 → 证据关系 → 原子陈述 → 原文片段”链条逐层回溯到冻结原文。

本文总结系统的方法论、关键工程机制与验证结果。核心数据：混合召回将金标证据 recall@20 从 0.7333 提升至 1.0000 (4 条金标陈述全部找回, 0 丢失)；发布门禁 10 项检查中 9 项通过、1 项按设计跳过；验证体系覆盖 218 个后端测试、62 个前端测试、32 条端到端用例，并已全部接入 CI 与 main 分支保护。

1. 背景与问题

专业行业研究员的日常不是浏览一次性报告，而是持续处理新材料、审核机器提议、维护行业命题、识别证据冲突，并把已验证的研究关系穿透到公司、股票、估值与基金披露持仓 (PRODUCT.md)。

现有工具的三个结构性缺陷：

- 结论与证据脱节**：AI 生成的研究结论无法回溯到具体原文位置，无法回答“这句话凭什么这么说”。
- 人机边界模糊**：机器草稿与人工结论混在一起，复核动作覆盖原始输出，审计无从谈起。
- 时间语义缺失**：“当前状态”掩盖了信息可见性——站在历史时点回放时，后公开的材料不应出现。

系统的设计回应是三条不可妥协的原则：**证据始终可追溯**、**AI 与人工边界可见**、**时点可回放**。

2. 方法论：不可变账本上的研究语义

2.1 核心词汇表 (Ubiquitous Language)

系统对研究对象做了严格的语义区分 (CONTEXT.md)，每个概念都有明确的“反义词”防止退化：

概念	定义	明确不是
Thesis	可检验、可证伪、有时间边界的命题	主题、结论、推荐
AIAssessment	基于冻结证据快照的 不可变临时 AI 判断，在人工决策前始终显著标记为未复核	最终结论、置信分数
ReviewDecision	不可变人工决策，确认/修改/驳回并记录理由， 不替换机器输出	编辑、审批标志、可变状态
Proposal	机器或人工提出的关系建议，经人工复核发布前不是正式研究关系	证据、已批准关系
SourceStatement	来源明确做出的原子陈述（披露事实/管理层归因/预测/研究观点）	客观事实
EvidenceLink	解释某陈述为何在特定时间与范围内支持/反驳/补充某命题的带版本论证	自动 SUPPORTS 边、语义相似度
EvidenceSnapshot	一次 AI 评估在其截止时间点可见的冻结集合	当前数据库状态

2.2 三条架构原则

原则一：一切判断可回溯到冻结原文。 每个 AIAssessment 必须能沿 评估 → EvidenceSnapshot → EvidenceLink → SourceStatement → SourceSpan 链条追到带确切位置（页区/段落/表格单元格/字符区间）的原文片段。这不是产品文案，而是门禁检查 3（assessment_source_spans_complete）的强制约束。

原则二：AI 与人工是两类记录，不是两种状态。 AI 结论永远标记为临时（displayed_as_provisional = True）；人工复核以独立的 ReviewDecision 追加，原始机器结论保持原样。门禁检查 6、7 分别强制"边界可见"与"每个 AI 判断都有人工复核记录"（review_coverage == 1.0）。

原则三：时点可回放。 历史截止日之后的材料（含基金持仓披露）必须从技术视图中消失。门禁检查 5（future_material_excluded）用 cutoff=2026-04-01 验证后公开披露不出现在敞口计算中。

2.3 谨慎的投资映射

研究关系向证券的映射经过显式的 ThemeRole（公司在主题中的角色，含适用范围与期间）与 Expression（考虑估值、敞口、新鲜度与约束后的敞口表达）两层抽象——敞口表达**本身不是推荐**。基金侧只使用带报告期与发布日期双时间戳的持仓披露（门禁检查 4 强制），杜绝"实时持仓"幻觉。

3. 系统架构

前端 (React 18 + Vite, PrototypeShell 主题化外壳)
主题 → 工作台 → 审核中心 → 数据中心 → 快照版本
契约层 (OpenAPI → openapi-typescript 生成 v1.ts)
后端 (FastAPI + SQLAlchemy, /api/v1)
RecallService ExposureService WorkbenchService
ComplianceGate ResearchOpsKPI PdfTextService
不可变账本 (sqlite/PostgreSQL, Alembic 迁移)
可选投影 (Neo4j, 可从账本完整重建)

前端与后端通过 OpenAPI 契约生成类型（`frontend/src/contracts/v1.ts`），前端另有内存 mock 适配器，使界面开发与 e2e 测试不依赖后端可用性。

4. 关键工程机制

4.1 混合召回 (P0)

问题：粗粒度分词器把整段中文连续文本切成单个大 token，使部分金标证据对 BM25 完全不可见（寒武纪命题的 3 条证据即属此列）。

方案：`RecallService` 采用三路融合——BM25（粗 token）+ 本地确定性 char-n-gram TF-IDF 稠密路（恢复子词匹配）+ 词汇信号，以 RRF 融合；`mode="bm25"` 保留为评估基线。真实嵌入后端可在同一契约后替换 `tfidf_rank`。

结果（`backend/scripts/eval_recall_ab.py`，冻结切片离线回放）：

指标	BM25 基线	混合召回
总体 recall@10	0.6667	0.7333
总体 recall@20	0.7333	1.0000

4 条金标陈述全部找回、0 丢失；脚本内置“混合不得低于基线”的回退守卫，低于基线即退出码 1。

4.2 真实 PDF 解析路径 (P1)

第二金标案例"锂电储能链"引入了首个真实二进制 PDF fixture (阳光电源年报摘要)。

`app/services/pdf_text.py` 将 PDF 文本层解析为可复现的 SourceSpan (CJK 软换行重组、表格块行保留)，无文本层 PDF **fail-closed**；文档加盖 `parser_version=pypdf-v1` 戳。门禁检查 9 以 sha256 哈希 + 金标事实双重校验：fixture 被重新生成而未重冻结清单、或 pypdf 升级改变抽取行为，都会使门禁失败。

4.3 合规重写回路 (P2)

三动作合规契约：REFUSE 类命中直接拒绝、不进入重写；REWRITE 类命中 (目标价/收益承诺) 获得**恰好一次** LLM 重写 (`rewrite-v1 prompt`)，重写结果经同一合规门复检，残留命中则整个运行拒绝。被修复的评估在 AIRun 上记录 `rewritten_for_compliance`；前端以 422 感知被拒绝的重跑。

4.4 研究效能 KPI (P3)

`GET /api/v1/research-ops/kpis` 只从账本推导管理指标，无自报数字：审核吞吐 (含按审核人分布与待审队列)、人机一致率 (评估级与链路级，无数据时返回 null 而非编造)、判断时滞 (证据→AI 判断、AI 判断→首次人工复核，以天计)。支持 `as_of` 时点回放。前端数据中心页以"研究效能"区块呈现，空态诚实显示"暂无数据"。

5. 验证体系

验证是本系统的一等公民，分四层：

5.1 双金标案例与发布门禁

两个冻结案例 (AI 算力链 + 锂电储能链) 构成金标语料。发布门禁

(`backend/scripts/verify_ai_compute_slice.py`，一键复现 `docs/evaluation/reproduce.sh`) 执行 10 项显式检查，fail-closed 设计：数据集清单缺失时在**触碰数据库之前**退出。

#	检查	语义	最新结果
1	document_versions_present	≥6 份冻结文档版本	PASS
2	gold_manifest_matches_ledger	清单哈希集与账本精确一致 (fail-closed)	PASS
3	assessment_source_spans_complete	每个评估可回溯至原文片段	PASS
4	holding_disclosures_dated	持仓披露双时间戳齐全	PASS
5	future_material_excluded	历史时点不泄漏未公开材料	PASS
6	ai_human_boundary_visible	AI 临时标记 + 复核独立记录	PASS
7	review_outcomes_tracked	复核覆盖率 1.0	PASS
8	table_extraction_gold_accuracy	表格抽取精确复现金标 (fail-closed)	PASS
9	pdf_fixture_parse_gold	PDF 二进制解析端到端复现 (fail-closed)	PASS
10	projection_rebuilds	图投影可从账本重建 (无 Neo4j 时跳过, 不判失败)	SKIP

(来源: docs/evaluation/reports/20260802T070947Z.json)

每次运行生成带时间戳的摘要 JSON 并入库留存, 形成门禁趋势记录。

5.2 单元与契约测试

后端 218 个 pytest (sqlite 默认, pg/neo4j 标记测试无环境时自动跳过); 前端 62 个 vitest (含 mock 适配器行为与 HTTP 适配器契约)。

5.3 端到端测试

32 条 Playwright 用例分三层: **结构层** (新外壳全页面锚点与可访问性)、**只读层** (模式无关断言, mock 与真实后端均可通过)、**写入闭环层** (审核决策 → 队列收缩 → 审计入口 → 快照版本页)。写入用例通过 `?client=mock` 测试钩子强制内存适配器, 并附带"全程零 API 请求"的防护断言, 杜绝决策落入真实后端。

5.4 CI 与分支保护

两条 GitHub Actions 流水线: `backend-ci` (pytest + 门禁独立 job)、`frontend-ci` (tsc + vitest + Playwright)。main 分支保护要求全部 4 项检查通过方可合并 (strict 模式), 禁止 force push 与分支删除。

验证体系自身的价值已被实证: CI 首跑即发现"本地绿、提交树红"的不一致 (接口扩展漏同步代理层 + 未提交改动被单独入库), 这类问题在分支保护下将无法进入 main。

6. 结果汇总

维度	结果
金标证据召回	recall@20: 0.7333 → 1.0000
发布门禁	9 PASS + 1 SKIP (按设计)
测试规模	后端 218 / 前端 62 / e2e 32
CI	双流水线全绿 (ba07d3a)
分支保护	4 项必需检查 + strict + 禁 force push

7. 局限与未来工作

已知局限：

- 金标集规模小（2 案例、15 金标陈述），recall@20 = 1.0 不应外推为普遍水平；需要第三、第四案例扩大覆盖。
- 混合召回的稠密路是确定性 TF-IDF 占位，真实嵌入后端尚未接入（契约已预留）。
- mock 适配器的快照版本视图是冻结 fixture，“决策 → 新快照数据”联动仅由后端集成测试覆盖。
- Neo4j 投影检查在 CI 中跳过，图投影回归需带服务的流水线变体。

未来工作：

- 嵌入后端替换 `tfidf_rank`，并用同一 A/B 脚本对比；
- 金标集扩充至多行业（半导体、新能源外的新案例）；
- 带 Neo4j/PostgreSQL 服务的 CI 变体，解锁 `pg_only` / `neo4j_only` 测试与门禁检查 10；
- 研究效能 KPI 的趋势视图（当前为单时点）。

8. 复现

```
# 发布门禁 (10 项检查)
docs/evaluation/reproduce.sh

# 召回 A/B 评估
cd backend && python scripts/eval_recall_ab.py

# 后端测试
cd backend && python -m pytest -q

# 前端测试与 e2e
cd frontend && npm test && npm run e2e
```

本报告所有数据均可沿上述复现路径验证；门禁与召回结果引用自 `docs/evaluation/reports/` 中入库的带时间戳运行记录。